

Klassifikation und Analyse aus Stromdaten im Haushalt mit neuronalen Netzen

Tim Schrodi

01.01.2018

Inhaltsverzeichnis

1	Einleitung	1
2	Grundlagen	3
2.1	Maschinelles Lernen (Machine Learning)	3
2.1.1	Künstliche Intelligenz	3
2.1.2	Einführung	3
2.1.3	Lernprozess	4
2.2	Neuronale Netze	5
2.2.1	Aufbau	5
2.2.2	CNN - Convolutional Neural Network	9
2.2.3	RNN - Recurrent Neural Network	9
2.3	Physikalische Grundlagen zur Netzaktivität	9
2.4	Erhebung der Messdaten	9
2.4.1	Klassifikation der Messdaten	10
2.5	Visualisierung	11
3	Ausführung	13
3.1	Manuelle Analyse	13
3.2	Vorbereiten der Daten	17
3.3	Neuronales Netz	18
3.4	Trainingsprozess	22
3.4.1	Ergebnisse	23
3.5	Auswertung der Ergebnisse	24
4	Ergebnis	27
5	ProduktivBetrieb	28
6	Wirtschaftlichkeit	29
7	Ausblick	30

Zusammenfassung

Das Ziel dieser Studienarbeit war es mit Hilfe von verschiedenen Machine Learning-Methoden aus Stromdaten eines Haushalts verschiedene Geräte zu klassifizieren. Dazu wurden mit einem Messgeräte die allgemeine Spannung, Frequenz und verschiedene Oberwellen eines üblichen Stromnetzwerks eines privat Haushalts über mehrere Monate erfasst. Hinzu wurden manuell verschiedene Geräte wie eine Kaffemaschine oder eine Mikrowelle klassifiziert. Anhand der Stromverläufe und den dazu klassifizierten Geräten wurden verschiedene neuronale Netze trainiert und miteinander verglichen. Außerdem wurde versucht mit unüberwachten Lernen Gemeinsamkeiten innerhalb des Stromverlaufs ohne vorherige Klassifizierung zu erkennen.

Auch wurde die Wirtschaftlichkeit sowie der produktive Einsatz der Ergebnisse beachtet. Die neuronalen Netze, welche die besten Ergebnisse erzielten werden außerdem im produktiv Betrieb getestet und eingesetzt.

Kapitel 1

Einleitung

Was bis vor kurzer Zeit nur ein wissenschaftlicher Teil der Informatik war, erhält nun immer größere Bedeutung und Einfluss in vielen weiteren wirtschaftlichen und wissenschaftlichen Themen. Seit Google, Facebook, etc. große Fortschritte in diesem Bereich erzielen und Maschinelles Lernen auch in produktivem Betrieb Einsatz findet, liegt es Nahe dies auch auf bisher unberührten Branchen auszuweiten.

Eine dieser neuen Branchen ist die elektrische Energiewirtschaft, welche unter anderem die elektronische Infrastruktur und somit auch die Grundversorgung an elektrischer Energie bereitstellt. Die Versorgung von privaten Haushalten sowie Firmen mit elektrischer Energie ist mit der immer schneller wachsenden Nachfrage nach diesem Rohstoff, eine nicht mehr wegzudenkende Kernindustrie, welche immer noch große Wachstumschancen hat. In dieser Arbeit wird Data-Mining auf elektrotechnische Größen angewendet um weiterführende semantische Aussagen über diese Werte zu erhalten. Es werden verschiedene Netzdaten und dazugehörige Verläufe aufgezeichnet und mithilfe von verschiedenen Methoden von Maschinellern analysiert. Hauptbestandteil ist die Mustererkennung in den aufgenommenen Verläufen und deren Zuordnung zu verschiedenen Geräten in einem Haushalt. Hierbei sollen verschiedene normale Haushaltgeräte, wie Kaffeemaschinen oder Fernseher, welche in einem Stromnetz eines privaten Haushalts erkannt werden um somit Aussagen über Laufleistungen zu treffen. Außerdem wird auf die wirtschaftliche Nutzung des resultierenden Modells, sowie deren Produktivbetrieb eingegangen.

Für die maschinelle Analyse wird die Keras-API¹ mit Tensorflow im Backend

¹<https://keras.io/>

verwendet. Die Datenverarbeitung, Visualisierung sowie die Trainings- und Testphasen werden mit Python² umgesetzt.

²<https://www.python.org/>

Kapitel 2

Grundlagen

2.1 Maschinelles Lernen (Machine Learning)

Wenn man Maschinelles Lernen oder Künstliche Intelligenz hört, denkt die Mehrzahl an Roboter mit eigenem Bewusstsein und Denken wie in vielen Science Fiction Filmen dargestellt. Jedoch ist Maschinelles Lernen mittlerweile keine Zukunftstechnologie mehr. Bereits in den 60er Jahren gab es erste Versuche der Wissenschaft Künstliche Intelligenz zu erschaffen. Doch was ist Maschinelles Lernen wirklich? Und was bedeutet es für einen Computer zu lernen?

Dieses Kapitel beschäftigt sich mit diesen Fragen und gibt einen kurzen Überblick über heutige Verfahren von Maschinellern Lernen.

2.1.1 Künstliche Intelligenz

Bevor Maschinelles Lernen erklärt werden kann sollte Künstliche Intelligenz im allgemeinen geklärt werden.

2.1.2 Einführung

Nimmt man den Begriff Maschinelles Lernen wörtlich beschreibt er das Lernen einer Maschine, also die Fähigkeit einer Maschine intelligenter zu werden. Von Maschinellern Lernen spricht man, falls eine Maschine auf Basis von Erfahrung und Fakten „ohne speziell programmiert worden zu sein“ [1, 20], neues Wissen oder neue Zusammenhänge generieren kann. Wenn eine Maschine nachdem sie etwas gelernt hat bei der Ausführung einer Aktivität besser geworden ist, hat die Maschine maschinell gelernt [1, 20]. Das reine auswendig lernen von Fakten, wie beispielsweise das abspeichern einer Wikipedia-Seite

auf die lokale Festplatte eines Computers, ist kein Wissenserwerb.

Ein Beispiel für Maschinelles Lernen ist der Spamfilter bei Emails. Hier lernt ein Computer auf Basis von bisherigen Spammails neue Emails als Spam zu erkennen.

Der Einsatz von Maschinellern Lernen hat meist Vorteile gegenüber herkömmlichen Statistischen Methoden falls große Datenmengen ausgewertet werden müssen oder kein bekanntes Modell zur Problemlösung bekannt ist. Durch Maschinelles Lernen können Zusammenhänge erkannt werden, die durch andere statistische oder algorithmische Verfahren nicht erkannt oder abgebildet werden können.

2.1.3 Lernprozess

Grundlegend besteht Maschinelles Lernen aus einer Trainingsphase und einer Test- beziehungsweise Validierungsphase. In der Trainingsphase wird auf Basis von Daten, wie bisherige Emails eines Benutzers, ein Modell erstellt, welches dann in der Validierungsphase auf seine Genauigkeit überprüft wird. Aus dem Ergebnis der Validierungsphase sowie der sonstigen Wissensbasis kann nun eine neue Trainingsphase durchgeführt werden(vgl. 2.1).

Dieser Prozess wird Epoche genannt und kann nun beliebig oft wiederholt werden und das Modell weiter verbessert werden. Das entstandene Modell ist das neu generierte Wissen.




Abbildung 2.1: Trainingsprozess ([1, Figure 1-2])

2.2 Neuronale Netze

Neuronale Netze sind eine Form von Machinellem Lernen und die heute am meisten eingesetzte Technik.

2.2.1 Aufbau

Ein künstliches neuronales Netz ist an das menschliche Gehirn angelehnt und soll dessen neuronales Netz sowie dessen Verhalten abbilden. Dementsprechend besteht ein solches Netz aus mehreren Neuronen und Schichten von Neuronen welche über Synapsen miteinander verbunden sind.

Neuronen

Neuronen bestehen aus Eingängen, auch Dendriten genannt, welche durch eine Eingangsfunktion, eine Aktivierungsfunktionen sowie eine Ausgabefunktion geleitet werden. Die Ausgabe eines Neurons besteht daraus dass dieses je nach Eingabe und Art entweder angeregt(„gefeuert“) wird oder nicht.




Abbildung 2.2: Aufbau eines Neurons

Die Eingangsfunktion berechnet aus den verschiedenen Eingängen den effektiven Eingang welcher dann weiter von der Aktivierungsfunktion verarbeitet wird. Diese effektive Eingabe ist dann die Netzeingabe in das Neuron. Meist wird die Netzaktivität net einfach als Summe aller Eingänge x und deren Gewichtungen w errechnet:

$$net = \sum_{i=0}^N x_i w_i \quad (2.1)$$

Die Aktivierungsfunktion dient zur eigentlichen Auswertung der Eingabe bzw. Netzaktivität. Die Aktivierungsfunktionen erzeugt ein Aktivierungspotential welches von der Ausgangsfunktion ausgewertet wird.

Die Ausgangsfunktion entscheidet schlussendlich ob das Neuron angeregt wird oder nicht. Hierzu wird geprüft ob das Aktivierungspotential der Aktivierungsfunktion einen bestimmten Schwellenwert übersteigt. Dieser Schwellenwert wird mithilfe einer Schwellenwertfunktion errechnet. Die Schwellenwertfunktion muss monoton wachsend sein, kann jedoch verschiedene Formen annehmen. Sie kann linear Verlaufen wie es beim Perzeptron der Fall ist, nicht-linear oder eine Sprungfunktion sein. Durch eine nicht-lineare Funktion wie die Sigmoid-Funktion lassen sich mächtigere neuronale Netze entwickeln weshalb heutzutage meist eine solche zum Einsatz kommt.

Topologie

Bei einem neuronalen Netz sind dessen Neuronen über Synapsen, welche bestimmte Kantengewichte bzw. Biases haben, verbunden. Durch verschiedene Kantengewichte können Eingänge oder bestimmte Features priorisiert werden. Dies bedeutet, dass Eingänge welche größeren Einfluss auf das erwartete Ergebnis haben, höher gewichtet werden können und somit stärker in das Ergebnis mit einbezogen werden.

Durch verschiedene Verbindungen zwischen Neuronen ergeben sich verschiedene Topologien von Netzen:

Vorwärts-verkettete Netze, auch feed-forward Netze genannt, bestehen aus verschiedenen Neuronen-Schichten(hidden layers), welche nur mit der nächst höheren Schicht verbunden sind. Somit verlaufen die Daten nur in eine Richtung, vom Eingang zum Ausgang.

Rekurrente Netze können auch aus mehreren Neuronen-Schichten bestehen wobei hier auch Verbindungen in tiefere Schichten möglich sind. Dies bedeutet, dass auch Ergebnisse von vorherigen Durchläufen des Netztes als Eingang mit einbezogen werden können.

Voll-vernetzte Netze sind neuronale Netze, bei denen alle Neuronen mit allen anderen Neuronen vernetzt sind. Wobei hierbei keine wirkliche Struktur erkennbar ist und ein sehr großer Rechenaufwand besteht.




Abbildung 2.3: Netztopologien

Lernen

Bei neuronalen Netzen ist das vorhandene Wissen durch die Kantengewichte repräsentiert. Daraus folgt, dass verschiedene Klassifikationen von neuronalen Netzen, mit derselben Topologie, sich nur von den Kantengewichten abhängt. Dementsprechend lernt ein neuronales Netz durch das sequentielle Anpassen

der Gewichte. Dazu gibt es verschiedene Verfahren wie diese Gewichte angepasst werden können.

Beim **Backpropagation Lernen** werden in der Trainingsphase die Ergebnissen eines Durchlaufs mit den erwarteten Ergebnissen verglichen und der Ausgabefehler berechnet. Mithilfe dieses Fehlers wird nun Schichtweise versucht den Fehler auf einzelne Neuronen bzw. Gewichte bis hin zur Eingabeschicht zurückzuführen. Danach werden nun bei verschiedenen Neuronen Änderungen der Gewichte durchgeführt um den Fehler der Ausgabefunktion zu minimieren. Hierbei wird für jedes Gewicht mithilfe verschiedener Gradientenverfahren eine Änderung berechnet.

Beim **Batch Lernen** wird anders als beim Backpropagation Lernen nicht nach jeden Durchlauf des Netztes die Gewichte angepasst sondern erst nachdem das Trainingsset komplett durchlaufen wurde. Dies führt zu weniger Genauigkeit das nicht auf spezielle Eigenschaften einzelner Einträge eingegangen. Jedoch Ist dieses Verfahren sehr viel weniger Rechenaufwand und es können mehr Trainingsdaten in gleicher Zeit einbezogen werden.

Perzeptron

Ein sehr einfaches neuronales Netz ist das Perzeptron, welches 1958 von Frank Rosenblatt entwickelt wurde. Das Perzeptron besteht aus zwei Eingabeparametern, welche in ein Neuron gegeben werden und von diesem mithilfe der Kantengewichte und der Aktivierungsfunktion eine Ausgabe liefert.

Ein Beispiel ist die Abbildung des booleschen „Und“-Operators welche wie in Abbildung 2.4 mit einem Neuron dargestellt werden kann. Jedoch können mit einem Neuron nur sehr einfache Funktionen abgebildet werden. Komplexere Funktionen können über mehrere Neuronen bzw. mehrere Schichten von Neuronen abgebildet werden.




Abbildung 2.4: UND-Operator als Perzeptron

x1	x2	$(x_1 * w_1) + (x_2 * w_2)$	out
0	0	$(0 * 2) + (0 * 2) = 0 < 3$	0
0	1	$(0 * 2) + (1 * 2) = 2 < 3$	0
1	0	$(1 * 2) + (0 * 2) = 2 < 3$	0
1	1	$(1 * 2) + (1 * 2) = 4 < 3$	1

Tabelle 2.1: Wahrheitstabelle des Perzeptron

2.2.2 CNN - Convolutional Neural Network

2.2.3 RNN - Recurrent Neural Network

2.3 Physikalische Grundlagen zur Netzaktivität

2.4 Erhebung der Messdaten

Um aussagekräftige Analysen und Klassifikationen über ein Stromnetz bzw. die Geräte in einem Stromnetz mit Maschinellern Lernen machen zu können, werden viele Trainings- und Testdaten benötigt. Die Daten bestehen aus verschiedenen physikalischen Größen, die zu einem bestimmten Zeitpunkt in einem Stromnetz auftreten. Zu diesen Größen gehört die allgemeine Netzspannung, die Netzfrequenz sowie sieben harmonischen Oberwellen (vgl. 2.3). Um einen allgemeinen Überblick über den Verlauf der Netzaktivität zu erhalten sowie verschiedene Zeiten und Geräte vergleichen zu können, müssen Daten über lange Zeiträume erhoben werden.

Zur Erhebung der Werte zur Netzaktivität wurde ein WeSense-Messgerät¹ verwendet. Dieses Gerät misst alle benötigten Werte und sendet diese über einen MQTT-Broker² an einen Service von WeSense, welcher dann die Daten aufbereitet und in einer MSSQL Datenbank abspeichert. Die Werte werden sekundlich gemessen und in die Datenbank gespeichert, weshalb zunächst in eine row-based Datenbank gespeichert wird und später dann die Daten in eine column-based Datenbank zur schnellen Abfrage überführt werden.

¹<http://www.wesense-app.com/home-en/>

²Message Queuing Telemetry Transport

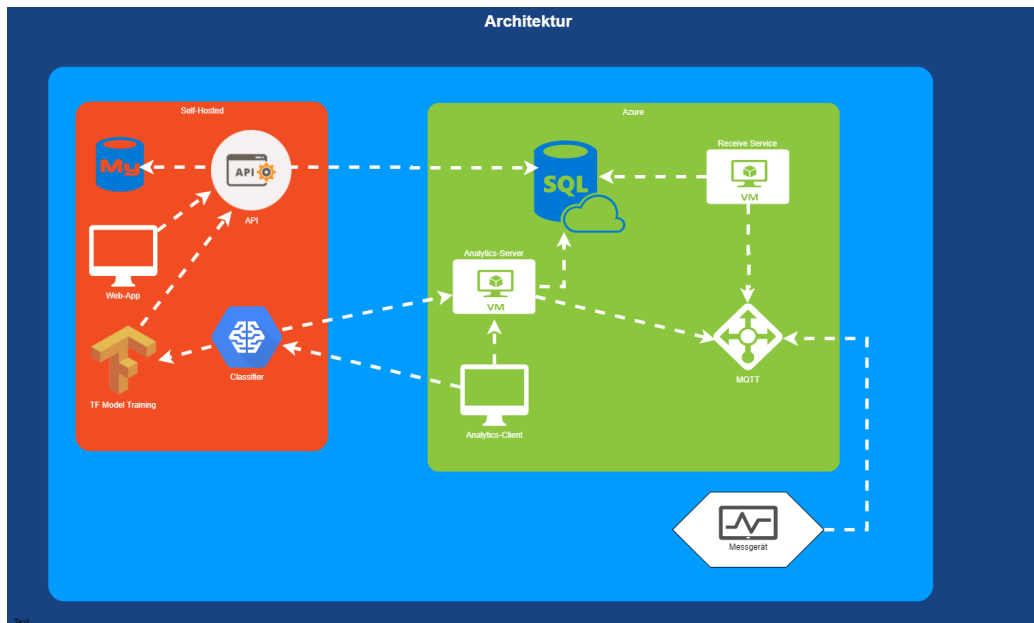


Abbildung 2.5: Complete Architecture

2.4.1 Klassifikation der Messdaten

Durch die oben beschriebene Erhebung sind die physikalischen Werte zu bestimmten Zeitpunkten bestimmt worden. Zusätzlich wird nun zur Identifikation der Geräte sowie zum Maschinellen Lernen, genau definierte Zeiträume benötigt in denen bestimmte Geräte aktiv waren. Dies bedeutet, dass jedem Zeitpunkt ein oder mehrere Geräte zugewiesen werden.

Um diese gelabelten Daten zu erheben gibt es verschiedene Möglichkeiten. Die Daten können entweder durch eine Person, welche Zeiten zu denen sicher Geräte aktiv waren manuell erfasst, oder durch eine Maschine automatisch erhoben werden. Jedoch wird zur automatischen Erhebung ein weiteres Gerät benötigt, welches zwischen dem zu messenden Gerät und dem Stromnetz zwischengeschaltet wird und sobald Strom fließt Daten erfasst. Somit werden die manuell durch eine Person erfasst.

Hierzu wurde eine progressiv Web-App(vgl. Abbildung 2.6) mit einer einfachen MySQL-Datenbank erstellt, mit der die Daten sehr einfach erfasst und abgespeichert werden können.




Abbildung 2.6: Screenshot der progressive Web-App

2.5 Visualisierung

Zusätzlich zur manuellen Erhebung der Daten wurden zur besseren Analyse der Daten verschiedene Visualisierungsmöglichkeiten implementiert. Zum einen können die verschiedenen Physikalischen Größen eines gelabelten Gerätes zu einem bestimmten Zeitpunkt miteinander verglichen werden. Außerdem können bestimmte Größen zu verschiedenen gelabelten Zeiträumen eines Gerätes verglichen und analysiert werden. Durch diese Visualisierung können sehr gut und genau Gemeinsamkeiten in verschiedenen Größen oder Zeiten erkannt werden.

Es werden verschiedene Diagramme sowie Normalisierungen der Daten zur Analyse bereitgestellt. Es besteht die Möglichkeit die Daten in einem Liniendiagramm sekundlich oder in frei wählbaren zusammengefassten Datenpunkten, sogenannten Klassen, anzuzeigen. Des weiteren können Histogramme mit verschiedenen Klassen gewählt werden.



Abbildung 2.7: Screenshot eines gelabelten Zeitraumes aus der Web-App

Kapitel 3

Ausführung

Dieses Kapitel beschreibt die Vorgehensweise von der ersten manuellen Analyse der Daten bis zum fertigen Produkt. Als Beispielprodukt für die Klassifizierung wurde eine Senseo Kaffeemaschine gewählt, da durch häufige Benutzung viele Daten erhoben werden können. Außerdem wurde eine Mikrowelle als zweite Gerät mit wenigen Daten gewählt um verschiedene Parameter und Kennzahlen zu vergleichen. Hierbei soll die Anzahl der Daten sowie die Klassifikation von mehreren Geräten innerhalb eines Neuronalen Netzes untersucht werden.

3.1 Manuelle Analyse

Zur manuellen Analyse der Daten wird das in 2.5 beschriebene Tool verwendet. Zunächst werden sehr aussagenkräftige Größen wie die Spannung oder die Frequenz der Kaffeemaschine verwendet und mit anderen aktiven Zeiträumen der Kaffeemaschine verglichen. Hierbei kann ein sehr spezifischer Verlauf der Spannung erkannt werden.

Wie in Schaubild reffig:Spannungsverlauf zu sehen ist, ist die Kurve zu Beginn start fallend und verbleibt dann eine gewissen Zeit auf diesem Tief. nach einem längeren steigenden Abschnitt fällt die Kurve wieder bis der Zubereitungsvorgang beendet wurde und wieder steigt.

Diesem Verlauf können nach mehreren Beobachtungen bestimmte Vorgänge einer Kaffeezubereitung zugeordnet werden. Zu Beginn der Kaffeezubereitung wird die Kaffeemaschine manuell eingeschaltet. Dies führt automatisch zum erwärmen des Brühwassers, welches dem ersten Fallen der Kurve zugeordnet werden kann. Da dort viel Energie benötigt um das Wasser zu erhitzen steigt der Stromverbrauch der Kaffeemaschine stark an und somit fällt die

Netzspannung stark ab. Die Netzspannung bleibt solange auf einem gewissen Tiefpunkt mit minimaler Netzschwankung bis das Wasser erwärmt wurde und ein weiterer manueller Schritt zum Fortfahren des Prozesses notwendig ist. Nach Wahl der Tassengröße wird dann der Brühvorgang gestartet. Dabei wird das erhitzte Wasser mit einem gewissen Druck durch einen Kaffeepad gepresst. Da dieser Druck bei der Senseo Kaffeemaschine durch eine elektronische Pumpe erzeugt wird, sinkt demnach die Netzspannung ab bis der komplette Kaffee durch gelaufen ist. Somit kann die Zweite Tiefpunktphase dem "Pressvorgang" der Kaffeemaschine zugeordnet werden.




Abbildung 3.1: Spannungsverlauf der Senseo Kaffeemaschine mit einer Klasse von je 3 Datenpunkten zu 2 verschiedenen Zeitpunkten

Bei der manuellen Analyse der Mikrowelle können bei Analyse des Spannungs- oder Frequenzverlaufs leider keine hervorstechenden Merkmale oder Gemeinsamkeiten erkannt werden. Somit wird die Mikrowelle demnach einen anderen Einfluss auf die Netzaktivität ausüben. Wie bei dem Vergleich der verschiedenen harmonischen Oberwellen zu sehen ist (siehe Schaubild 3.2), besteht eine große Ähnlichkeit der Kurven der dritten harmonischen Welle.




Abbildung 3.2: Verlauf der 3. harmonischen Oberwelle einer Mikrowelle mit einer Klasse von je 3 Datenpunkten zu 2 verschiedenen Zeitpunkten

Wie dieser Abschnitt zeigt können schon mit bloßen Auge bestimmte Auswirkungen der verschiedenen Geräte erkannt werden. Auch wenn einige Störungen auftreten und den Verlauf verfälschen, sollte es dennoch möglich sein diese Geräte herauszufiltern. Weiterführend wird dieser Prozess automatisiert und verbessert um auch trotz großer Störungen, Geräte präzise klassifizieren zu können.

3.2 Vorbereiten der Daten

Um die Klassifizierung der Geräte auf neuronalen Netzen abzubilden müssen die vorhandenen Daten in ein geeignetes Format transformiert werden. Dabei gibt es verschiedene Voraussetzungen zu beachten, sowie verschiedene Möglichkeiten die Daten zu transformieren.

Bei konventionellen Neuronalen Netzen werden Eigenschaften Objekten zugewiesen, wobei alle Objekte mit denselben Eigenschaften betitelt werden. Ein Beispiel dafür sind Tiere, bei denen anhand von Reproduktion oder Atmung in Säugetiere, Vögel, Reptilien, etc. eingeteilt wird. So können spezielle Tiere wie ein Hund einer dieser Klassen zugewiesen werden. Alle klassifizierten Tiere werden hierbei dieselben Eigenschaftsklassen mit unterschiedlichen Werten zugewiesen. Das heißt, dass einem Hund oder einer Taube die Anzahl der Beine und die Reproduktion zugewiesen werden, jedoch mit jeweils unterschiedlichen Werten.

Durch die in Kapitel 2.4 beschriebene Erhebung der Daten, werden die Stromdaten in einem bestimmten Format von der API bereitgestellt. Es werden 2 verschiedene Listen zurückgegeben wobei eine die reinen Messdaten enthält und die andere die Labels für diese Daten.

Die reinen Messdaten werden zusammengetragen, indem zu den gelabelten Zeiträumen jeweils alle sekundlich gemessenen Werte des Stromnetzes als eine Matrix eingefügt werden.

Zusätzlich zu den manuell klassifizierten Daten werden noch zufällig ausgewählte Zeitabschnitte hinzugefügt um die Möglichkeit „kein Gerät war aktiv“ abzubilden. Diese Abschnitte werden gewählt, indem zufällig Daten aus der Datenbank gewählt werden bei denen mit großer Wahrscheinlichkeit kein zu klassifizierendes Gerät aktiv war. Eine dieser Zeiträume könnte zum Beispiel von 00:00 bis 5:00 Uhr, da zu dieser mit hoher Wahrscheinlichkeit kein Gerät aktiv war.

Somit ergibt sich eine drei dimensionale Matrix welche in der ersten Dimension die Zeiträume abbildet, in der zweiten Dimension die sekundliche Zeitreihe und die dritte die vorhandenen physikalischen Größen.

Listing 3.1: Datenstruktur der gelabelten Messdaten, die von der API bereit gestellt wird

[

```

[
    [u, f, h3, h5, h7, h9, h11, h13, h15],
    [u, f, h3, h5, h7, h9, h11, h13, h15],
    [u, f, h3, h5, h7, h9, h11, h13, h15],
    ...
]
]

```

Da Neuronale Netze feste Eingabegrößen benötigen, werden die Daten in Batches aufgeteilt. Batches bedeutet, dass die Zeitreihe in gleich große Abschnitte aufgeteilt wird. Dementsprechend wird die Matrix $A[m, n, 9]$, zu einer Matrix mit einheitlicher Größe transformiert, sodass die entstehende Matrix zum Beispiel die Form $B[m, 20, 9]$ annimmt.

Um diese neue Matrix zu erhalten wird folgender Algorithmus auf die alte Matrix angewandt:

Algorithm 1 Batch Generierung

```

1: function GENERIEREBATCHES( $A, b$ )
2:                                     ▷  $A$  - float[[]],  $b$  - int (Batchgröße)
3:    $B = \text{Array}[][]$ 
4:   for  $i = 0$  to  $\text{length}(A)$  do
5:     for  $j = 0$  to  $\text{length}(A[i]) - b$  do
6:        $start = j$ 
7:        $end = j + b$ 
8:        $I_b = \text{length}(B) + 1$ 
9:        $B[I_b] = A[i][start : end]$ 
10:    end for
11:  end for
12:  return  $B$ 
13: end function

```

3.3 Neuronales Netz

Wie Abschnitt 3.1 zeigt ist es möglich mit herkömmlichen manuellen Methoden verschiedene Geräte innerhalb eines Verlaufs zu klassifizieren. Somit sollte dies auch mit maschinellem Lernen möglich sein.

Um nun die Geräte maschinell zu klassifizieren, werden drei verschiedene „neuronale Netz“ Modelle erstellt und miteinander verglichen. Die drei Model-

le beinhalten ein „Recurrent Neural Network(RNN)“, ein „Convolutional Neural Network(CNN)“ sowie eine Mischung aus diesen Ansätzen. Bei allen Modellen wurde als Gradientenverfahren die Adam-Optimierung gewählt, da diese bei mehr Rechenaufwand bessere Ergebnisse erzielt.

CNN

Grundlegend besteht das Convolutional Neural Network aus einem „Input Layer“, drei „Convolutional Layers“, einem „Dropout Layer“ sowie einem „Output Layer“.

Das „Input Layer“ ist der Eingang zum neuronalen Netz, welcher die Rohdaten annimmt und an das eigentliche Netz weiterleitet. Es ist ein weiteres „Convolutional Layer“ und nimmt einen Eingabe-Tensor (Matrix innerhalb eines neuronalen Netzes), welcher an die Batchgröße angepasst ist. Dementsprechend hat der Eingabetensor die Form $A[m, b, 9]$, mit m: Trainingsdatengröße und b: Batchgröße.

Die Eingabe wird dann weitergeleitet an die drei „Convolutional Layers“, welche mit unterschiedlicher „Hidden Layer“-Größe initialisiert werden. Wobei die „Hidden Layer“ größer werden je näher sie topologisch an dem „Output Layer“ liegen.

Das „Dropout Layer“ wird eingefügt um die Tensordimension zu verkleinern und somit das Ergebnis zu generalisieren und Overfitting zu vermeiden.

Das „Output Layer“ wandelt nun die Erkenntnisse der vorherigen Schichten in ein lesbares Format um. Hierzu wird ein „Dense Layer“ verwendet, welcher ein eindimensionaler Tensor mit einem Feld pro klassifizierbaren Objekt ist und die Softmax-Funktion als Aktivierungsfunktion beinhaltet. Dieser eindimensionale Tensor repräsentiert pro Feld die Ausgabe pro zu klassifizierendem Gerät.




Abbildung 3.3: Convolutional Neural Network

RNN

Das „Recurrent Neural Network(RNN)“-Model besteht aus einem „Input Layer“, zwei darauffolgende „LSTM(Long short-term memory) Layer“ und einem „Output Layer“.

Das „Input Layer“ ist ein weiteres „LSTM Layer“ welche denselben Eingabetensor annimmt, wie das CNN-Model.

Es folgen zwei weitere „LSTM Layer“ einer „Hidden Layer“-Größe von 64 pro Schicht. Dieselbe Größe wird auch im Eingabe-„LSTM Layers“ verwendet.

Das „Output Layer“ ist, wie beim Convolutional Neural Network-Model, ein „Dense Layer“, der aus der Berechnung des Netzes eine verwertbare Ausgabe erzeugt.

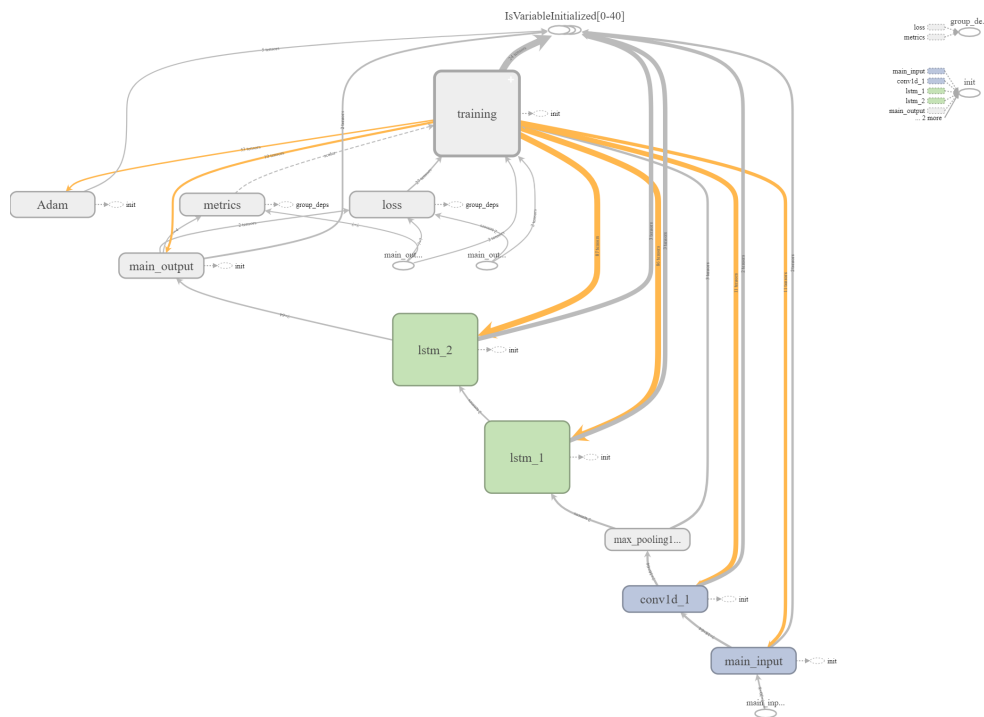


Abbildung 3.5: Convolutional Neural Network with Recurrent Neural Network

Die in diesem Abschnitt dargestellten Modelle stellen den Grundlegenden Aufbau der neuronalen Netze dar. Diese beinhalten jedoch keinerlei Wissen und können somit noch nicht zum Klassifizieren verwendet werden.

3.4 Trainingsprozess

Um die drei verschiedene Modelle anwenden zu können, muss diesen Modellen Wissen beigebracht werden. Dies geschieht durch Trainieren dieser Modelle mit den in Abschnitt 3.2 vorbereiteten Daten(vgl. Abschnitt 2.4.1). Damit die Modelle bestmögliche Ergebnisse erzielen, wird der Trainingsprozess mit verschiedenen Trainingsparameter sowie verschiedenen Daten durchlaufen. Die Trainingsparameter beinhalten die Batchgröße, die Anzahl der „Hidden Layers“, die Anzahl der zusätzlich gewählten Zeiträume sowie die genutzten physikalischen Größen.

Nach einigen Trainingsversuchen mit verschiedenen Trainingsparametern und Rohdaten wurde festgestellt, dass keine aussagekräftigen Ergebnisse erzielt

werden können. Da verschiedene Trainingsparameter keine großen Unterschiede in den Ergebnissen erzielen, werden verschiedene Transformationen der Rohdaten getestet. Als Transformation der Daten werden zwei verschiedene Verfahren gewählt.

Zum einen wird eine Normalisierung der Daten in Werte zwischen 0-1 durchgeführt, sodass größere Werte wie die Spannung, welche bei ca. 230V liegt, keinen höheren Einfluss auf das Ergebnis haben kann als die Frequenz.

Eine weitere Möglichkeit die Rohdaten zu transformieren ist die Ableitung über alle Werte zu errechnen und die entstandene neue Kurve zu klassifizieren. Somit wird vom neuronalen Netz der Verlauf der Kurve berücksichtigt um Geräte zu erkennen und nicht die reinen Rohwerte, welche je nach Netzwerk aktueller Aktivität stark abweichen kann.

3.4.1 Ergebnisse

Batchgröße

Lernrate = 0.001

Datentype = ['u', 'h3', 'h5', 'h7', 'h9', 'h11', 'h13', 'h15']

Epochen = 30

Ableitung = True

Model	Batchgröße	Genauigkeit	Validierungsgenauigkeit
CNN	20	0.966273284732199	0.951680388716426
RNN	20	0.8468702996644684	0.8470778782883545
MIX	20	0.8953488372093024	0.8924281279605352
CNN	30	0.9797050147492625	0.9505849965588438
RNN	30	0.8931563422180558	0.8902959394356503
MIX	30	0.9428908554923922	0.9296627666896077
CNN	40	0.9885078219013237	0.9894722066254913
RNN	40	0.9285800240673887	0.920550252633574
MIX	40	0.9690734055354994	0.9692588433129676
CNN	50	0.9921453117329406	0.9695017182130584
RNN	50	0.9582106038291606	0.9621993127147767
MIX	50	0.9874815905743741	0.9879725085910653
CNN	60	0.9949292600475773	0.9163014899385348
RNN	60	0.9661950669838487	0.9639205375401695
MIX	60	0.9917365719293852	0.9899211218229623

Tabelle 3.1: Ergebnis: Batchgröße

Tabelle 3.2: Ergebnis: Batchgröße

3.5 Auswertung der Ergebnisse

Nach der Klassifikation der Batches mit einem der neuronalen Netze sind für diese klassifizierten Batches mit n Datenpunkten für jeden Punkt n Klassifikationen vorhanden (vgl. Algorithmus 3.2). Somit muss diese Klassifikation ausgewertet werden um genau sagen zu können, zu welchen Datenpunkten (Zeitpunkten) Geräte aktiv waren und welches Gerät am wahrscheinlichsten aktiv war. Hierzu wird der Algorithmus in 3.5 verwendet, welcher die Treffer sowie die genaue Wahrscheinlichkeit pro Klasse zu einem bestimmten Zeitpunkt berücksichtigt. Dieser Algorithmus bestimmt die Anzahl der Gewinnerklassen (Klasse mit der höchsten Wahrscheinlichkeit) aller Batches in denen der bestimmte Datenpunkt vorhanden ist, und bestimmt nun aus dieser Anzahl wiederum die Gewinnerklasse (Klasse mit den meisten Treffern). Außerdem wird die Wahrscheinlichkeit aller Klassen in allen Batches des Datenpunktes summiert und wiederum die Gewinnerklasse bestimmt. Somit erhält man zwei verschiedene Gewinnerklassen, welche wiederum miteinander verglichen werden um die entgeltliche Gewinnerklasse zu bestimmen. Der Vorteil dieses Verfahrens ist die Berücksichtigung aller Klassifikationen sowie deren einzel Wahrscheinlichkeit, sodass sich eine genauere Klassifizierung ergibt.

Algorithm 2 Ergebnisauswertung

```
1: function EVALUATEPREDICTION( $P, b$ )
2:    $\triangleright P$  -  $\text{int}[]$  (Ergebnis eines neuronalen Netzes),  $b$  -  $\text{int}$  (Batchgröße)
3:
4:    $A = \text{int}[]$ 
5:   for  $i = 0$  to  $\text{length}(P)$  do
6:
7:     // Hit-Punkte aller Klassen für einen Zeitpunkt
8:      $\text{ClassesHit} = \text{int}[]$ 
9:     // Wahrscheinlichkeit aller Klassen für einen Zeitpunkt
10:     $\text{ClassesPerc} = \text{float}[]$ 
11:
12:    if  $i < b$  then
13:       $\text{start} = 0$ 
14:       $\text{end} = i$ 
15:    else
16:       $\text{start} = i - b$ 
17:       $\text{end} = i$ 
18:    end if
19:
20:    for  $d = \text{start}$  to  $\text{end}$  do
21:       $\text{maxClassIndex} = \text{argmax}(\text{pred}[d])$ 
22:       $\text{ClassesHit}[\text{maxClassIndex}] ++$ 
23:      for  $w = 0$  to  $\text{pred}[d]$  do
24:         $\text{ClassesPerc}[w] = \text{ClassesPerc}[w] + \text{pred}[d][w]$ 
25:      end for
26:    end for
27:
28:     $A.\text{append}(\text{EvaluateClasses}(\text{ClassesHit}, \text{ClassesPerc}))$ 
29:
30:  end for
31:  return  $A$ 
32: end function
```

Algorithm 3 Ergebnis-Klassen-Auswertung

```
1: function EVALUATECLASSES(ClassesHit, ClassesPerc)
2:                                     ▷ ClassesHit - int[], ClassesPerc - float[]
3:
4:   MaxHitClass = argmax(ClassesHit)
5:   MaxPercClass = argmax(ClassesPerc)
6:
7:   if MaxHitClass == MaxPercClass then
8:     return MaxHitClass
9:   else
10:
11:     MaxHitClassPerc = ClassesHit[MaxHitClass]/Sum(ClassesHit)
12:     MaxPercClassPerc = MaxPercClass[MaxHitClass]/Sum(ClassesPerc)
13:
14:     if
15:         MaxHitClassPerc < MaxPercClassPerc
16:     then
17:         return MaxPercClass
18:     else
19:         return MaxHitClass
20:     end if
21:   end if
22: end function
```

Kapitel 4

Ergebnis

Kapitel 5

ProduktivBetrieb

Kapitel 6

Wirtschaftlichkeit

Kapitel 7

Ausblick

MSSQL	Microsoft SQL-Server
CI	Continuous Integration
CD	Continuous Delivery
E2E	end to end
RNN	Recurrent Neural Network
CNN	Convolutional Neural Network

Abbildungsverzeichnis

2.1	Trainingsprozess ([1, Figure 1-2])	5
2.2	Aufbau eines Neurons	6
2.3	Netztopologien	7
2.4	UND-Operator als Perzeptron	8
2.5	Complete Architecture	10
2.6	Screenshot der progressive Web-App	11
2.7	Screenshot eines gelabelten Zeitraumes aus der Web-App . . .	12
3.1	Spannungsverlauf der Senseo Kaffeemaschine mit einer Klasse von je 3 Datenpunkten zu 2 verschiedenen Zeitpunkten	15
3.2	Verlauf der 3. harmonischen Oberwelle einer Mikrowelle mit einer Klasse von je 3 Datenpunkten zu 2 verschiedenen Zeit- punkten	16
3.3	Convolutional Neural Network	20
3.4	Recurrent Neural Network	21
3.5	Convolutional Neural Network with Recurrent Neural Network	22

List of Algorithms

1	Batch Generierung	18
2	Ergbnisauswertung	25
3	Ergebnis-Klassen-Auswertung	26

Literaturverzeichnis

- [1] Aurélien [VerfasserIn] Géron. *Hands-on machine learning with Scikit-Learn and TensorFlow : concepts, tools, and techniques to build intelligent systems*. OReilly, Beijing, first edition edition, March 2017.